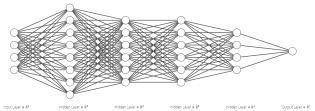
Un algorithme d'apprentissage pour l'agrégation de réseaux de neurones à activations binaires

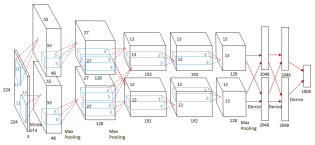
Louis Fortier-Dubois Gaël Letarte Benjamin Leblanc
Pascal Germain François Laviolette

4 avril 2022

Introduction

- Les réseaux de neurones : pourquoi sont-ils si difficile à analyser?
- La simplification comme solution
- Distribution de probabilité sur les poids du réseau
- Basé sur les travaux de *Letarte et al.*[1]

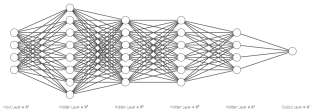


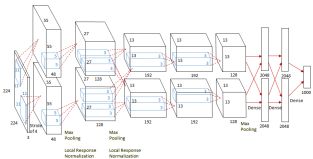


[1] Gaël Letarte, Pascal Germain, Benjamin Guedj, and François Laviolette. Dichotomize and generalize: PAC-Bayesian binary activated deep neural networks. NeurIPS, 2019.

Introduction

- Théorie PAC-Bayes
  - Borne de généralisation non-triviale
- Contributions
  - Se débarrasser d'une approximation
  - Prédiction en temps constant relativement à la profondeur du réseau





Plan de la présentation

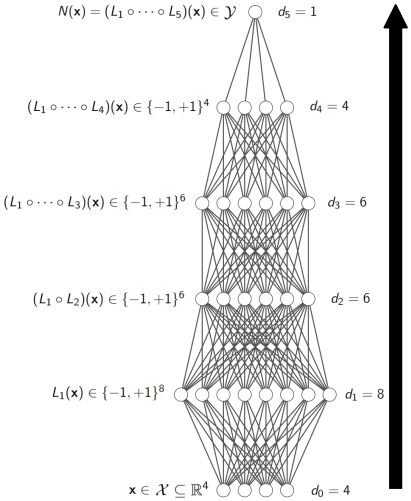
1. Notions préliminaires
2. Agrégation de réseaux de neurones
3. Expérimentations
4. Période de questions



Notions préliminaires

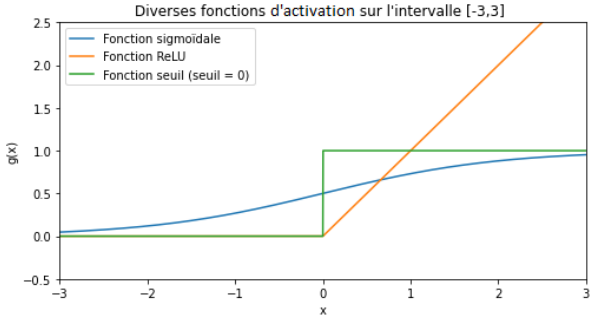
Les réseaux de neurones

- Réseaux pleinement connectés seulement
- Tâches de classification binaire
- $F(\mathbf{x}) = (L_1 \circ \cdots \circ L_l)(\mathbf{x})$
- $L_k(\mathbf{x}) = g_k(\mathbf{W}_k\mathbf{x} + \mathbf{b}_k)\ \forall k \in \{1, \ldots, l\}$



Pourquoi?

- Gains de temps de calculs
- Gains en mémoire requise
- Réseaux moins prompt au surapprentissage [1] [2]
- Possibilité d'interprétation



[1] J. Lin, C. Gan, and S. Han, "Defensive quantization: When efficiency meets robustness". CoRR, 2019
[2] M. Courbariaux, I. Hubara, D. Soudry, R. El-Yaniv, and Y. Bengio, "Binarized neural networks: Training deep neural networks with weights and activations constrained to +1 or -1". NIPS, 2016.

Étude des réseaux à activations binaires : rôle de chaque partie du réseau

Définition : les parties d'un réseau à activations binaires

- La première partie du réseau représente la première couche L_1
- La seconde partie du réseau représente le reste du réseau $(L_2 \circ \cdots \circ L_l)$

Étude des réseaux à activations binaires : rôle de chaque partie du réseau

Définition : les parties d'un réseau binaire

- La première partie du réseau représente la première couche L_1 et sert à assigner aux exemples reçus un *groupe*
- La seconde partie du réseau représente le reste du réseau $(L_2 \circ \cdots \circ L_l)$ et sert à assigner aux différents groupes une *prédiction*

Constatation : on a $L_1 : \mathcal{X} \to \{-1, +1\}^{d_1}$ et $(L_2 \circ \cdots \circ L_l) : \{-1, +1\}^{d_1} \to \mathcal{Y}$

Agrégation de réseaux de neurones

Aspect Bayesien

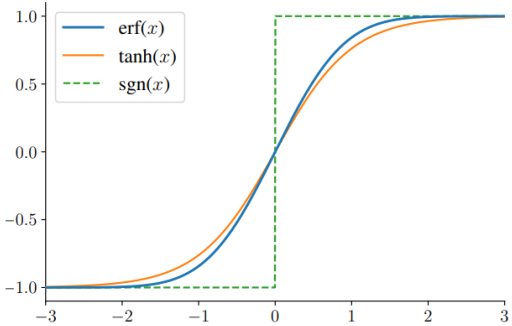
On suppose tous les poids $B = \langle \mathbf{W}_k \rangle_{k=1}^{l}$ d'une agrégation de réseaux suivant des distributions de probabilité Gaussienne, centrée en B et à matrice de covariance isotropique.

La sortie d'une neurone de l'agrégat

La sortie espérée d'une fonction signe avec distribution Gaussienne :

$$\underset{\mathbf{v}\sim\mathcal{N}(\mathbf{w},\mathbf{I})}{\mathbf{E}} \operatorname{sgn}(\mathbf{v}\cdot\mathbf{a}) = \operatorname{erf}\left(\frac{\mathbf{w}\cdot\mathbf{a}}{\sqrt{2}||\mathbf{a}||}\right) ,$$

avec $\operatorname{erf}(x) = \frac{2}{\sqrt{\pi}} \int_0^x e^{-t^2} dt$ étant la fonction d'erreur gaussienne.



Agrégation de réseaux de neurones

Probabilité d'observer une sortie donnée pour un neurone donnée

L'activation binaire agit à la façon d'une distribution de Bernoulli; on connait son espérance. La probabilité d'observer $s_i \in \{-1, +1\}$ est donnée par

$$\Pr(L_{k;i}(\mathbf{a}) = s) = \frac{1}{2} + \frac{s}{2}\operatorname{erf}\left(\frac{\mathbf{w}_{k,i} \cdot \mathbf{a}}{\sqrt{2}\|\mathbf{a}\|}\right), i \in \{1, \ldots, d_k\}, k \in \{1, \ldots, l\}.$$

Probabilité d'observer une sortie donnée pour une couche donnée

Soit $\Pr((L_1 \circ \cdots \circ L_k)(\mathbf{a}) = \mathbf{s}) = L^{\mathbf{s}}_{1,k}(\mathbf{a})$. De la même manière que pour la sortie d'une couche, la probabilité d'observer une certaine sortie chez une couche peut être calculée de façon itérative :

$$\Pr(L^{\mathbf{s}}_{1,k}(\mathbf{a})) = \begin{cases} \prod_{i=1}^{d_1} \Pr(L^{s_i}_{1,i}(\mathbf{a})) & \text{si } k = 1, \\ \sum_{\bar{\mathbf{s}}} \Pr(L^{\mathbf{s}}_{1,k}(\mathbf{a}) \mid L^{\bar{\mathbf{s}}}_{1,k-1}(\mathbf{a})) \Pr(L^{\bar{\mathbf{s}}}_{1,k-1}(\mathbf{a})) & \text{sinon.} \end{cases}$$

Le calcul exact de ABNet

Méthode de programmation dynamique

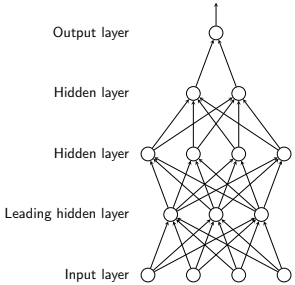
$$\text{Première couche : } \mathbf{P}_1(\mathbf{x}) = \left[\Pr(L_1^{\mathbf{s}}(\mathbf{a})) \right]_{\mathbf{s} \in R_1}$$

$$\text{Couches subséquentes : } \mathbf{P}_k = \left[\Pr(L_{1,k-1}^{\mathbf{s}}(\mathbf{a})) \right]_{\mathbf{s} \in R_k}$$

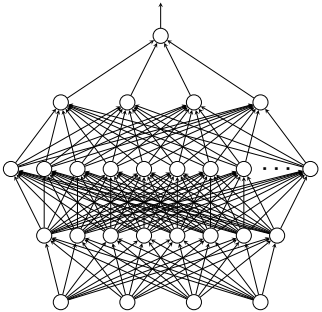
$$= \mathbf{\Psi}_k \cdot \mathbf{P}_{k-1} \ ,$$

$$\text{avec } \mathbf{\Psi}_k = \left[\Pr(L_{1,k}^{\mathbf{s}}(\mathbf{a}) \mid L_{1,k-1}^{\bar{\mathbf{s}}}(\mathbf{a})) \right]_{\mathbf{s} \in R_k, \bar{\mathbf{s}} \in R_{k-1}}$$

Agrégation de réseaux de neurones



(a) Un réseau de neurone typique.



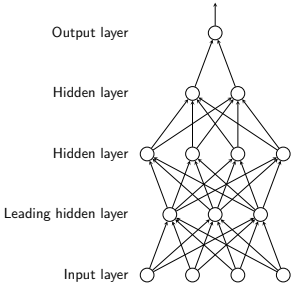
(b) L'architecture d'**ABNet**, avec comme réseau sous-tendu celui présenté en (a).

Agrégation de réseaux de neurones

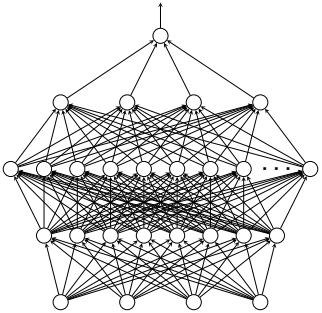
ABNet compact

$$\begin{aligned}\Pr(L^s_{1,l}(\mathbf{a})) &= s \cdot (\mathbf{\Psi}_l(\mathbf{\Psi}_{l-1}(\dots \mathbf{\Psi}_3(\mathbf{\Psi}_2\mathbf{P}_1(\mathbf{x}))\dots))) \\ &= \underbrace{s \cdot \mathbf{\Psi}_l \cdot \mathbf{\Psi}_{l-1} \cdot \dots \cdot \mathbf{\Psi}_3 \cdot \mathbf{\Psi}_2}_{\mathbf{H}_s} \cdot \mathbf{P}_1(\mathbf{x}))\end{aligned}$$

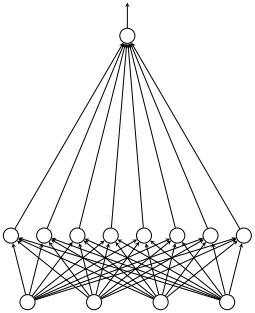
Agrégation de réseaux de neurones



(a) Un réseau de neurone typique.



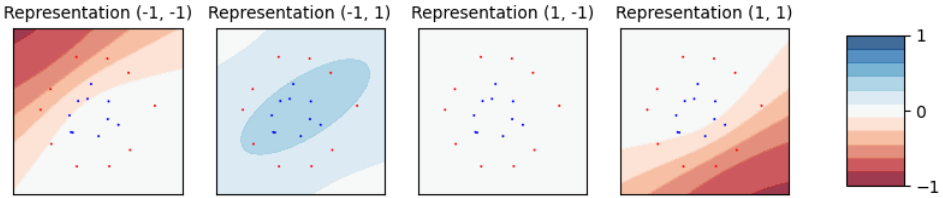
(b) L'architecture d'**ABNet**, avec comme réseau sous-tendu celui présenté en (a).



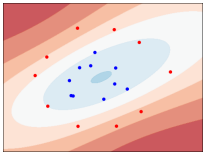
(c) La structure d'**ABNet compact**, obtenue à partir du ABNet en (b).

Expérimentations

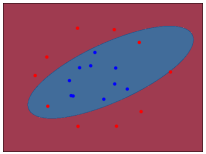
ABNet en pratique



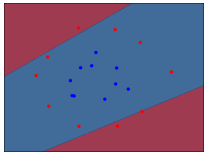
(a) Pour diverses valeur de $\mathbf{x}$, les probabilités d'avoir une certaine représentation en sortie de la première couche cachée, obtenues à partir de $\mathbf{P}_1(\mathbf{x})$, multipliées par $\mathbf{H}$.



(b) La sortie de l'agrégation $\Pr(L_{1,l})$.



(c) ABNet comme classifieur.



(d) Réseau unique, centré sur les moyennes *a posteriori* des lois Gaussiennes.

Expérimentations

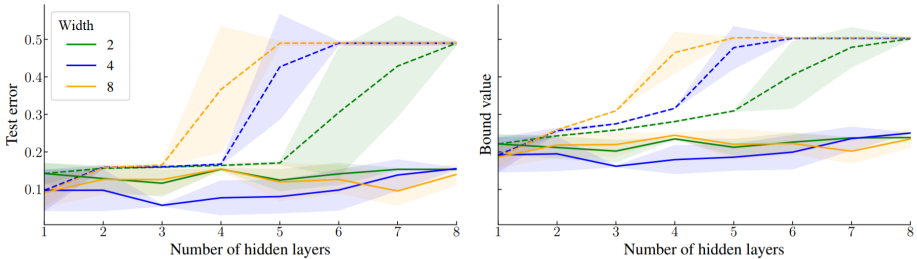


Figure: Impact de la profondeur pour **PBGNet (pointillé)** et **ABNet (continu)** sur l'erreur en test et la valeur de la borne selon la largeur pour le jeu de données mnistLH. 5 répétitions effectuées.

Expérimentations

Dataset	Model	$L-1$	d	Bound	Error_S	Error_T
ads	PBGNet	3	2	0.192 ± 0.004	0.140 ± 0.004	0.141 ± 0.012
	ABNet	3	2	0.192 ± 0.004	0.140 ± 0.004	0.141 ± 0.012
	PBGNet_ℓ	3	4	1.000 ± 0.001	0.018 ± 0.005	0.026 ± 0.004
	ABNet_ℓ	3	4	0.887 ± 0.064	0.015 ± 0.003	0.026 ± 0.003
	EBP	2	2	–	0.003 ± 0.002	0.040 ± 0.008
	BC	1	4	–	0.025 ± 0.005	0.031 ± 0.004
	BNN	1	8	–	0.037 ± 0.002	0.038 ± 0.004
mnistLH	PBGNet	1	8	0.186 ± 0.028	0.091 ± 0.037	0.092 ± 0.036
	ABNet	3	4	0.162 ± 0.001	0.056 ± 0.001	0.058 ± 0.002
	PBGNet_ℓ	3	8	1.000 ± 0.000	0.018 ± 0.003	0.038 ± 0.002
	ABNet_ℓ	2	8	0.998 ± 0.003	0.025 ± 0.008	0.042 ± 0.006
	EBP	3	8	–	0.016 ± 0.002	0.043 ± 0.002
	BC	2	8	–	0.023 ± 0.002	0.035 ± 0.001
	BNN	1	2	–	0.123 ± 0.005	0.133 ± 0.004

Questions / commentaires

Merci pour votre attention :) !