Réconcilier réseaux de neurones artificiels et interprétabilité

Benjamin Leblanc

16 mai 2023

Réconcilier réseaux de neurones artificiels et interprétabilité

Benjamin Leblanc

16 mai 2023

Interprétabilité - Définition

Nous définissons le degré d'interprétabilité d'un prédicteur par la capacité d'un non-expert à comprendre son processus de décision en ne considérant que le modèle en lui-même.

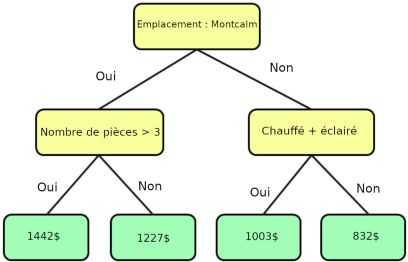
Interprétabilité - Exemples

Tâche: prédire le loyer mensuel d'un appartement dans la ville de Québec

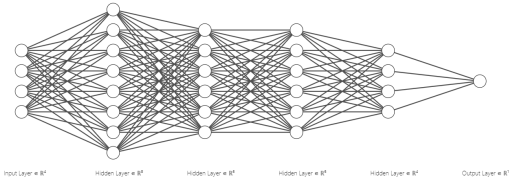
Modèle linéaire

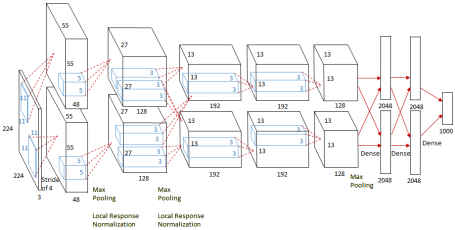
$$\hat{y} = 70\$ + 90¢ \cdot \text{nombre de pieds carré} + 58\$ \cdot \text{nombre de pièces}$$

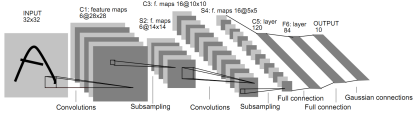
Arbre de décision



Réseaux de neurones artificiels

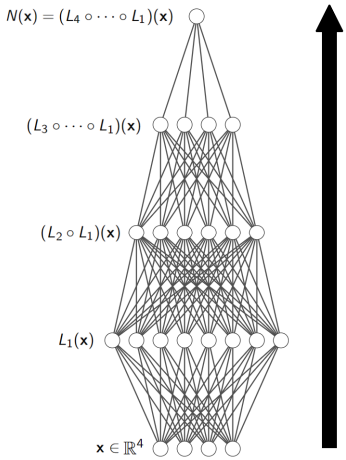






Réseaux de neurones artificiels

- Ici : réseaux pleinement connectés
- $B(\mathbf{x}) = (L_l \circ \cdots \circ L_1)(\mathbf{x}) = L_l(\dots L_2(\ L_1(\mathbf{x})\ )\dots)$
- $L_k(\mathbf{x}) = g_k(\mathbf{W}_k\mathbf{x})\ \forall k \in \{1, \dots, l\}$

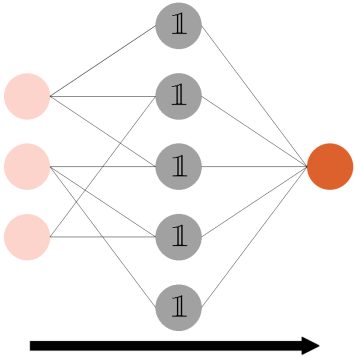


Réseaux de neurones simples

- Activations binaires (fonction *seuil*)

$$\mathbb{1}_{\{x\}} = \begin{cases} 1 & \text{si } x \text{ est vrai,} \\ 0 & \text{sinon.} \end{cases}$$

- Peu profonds (1 couche cachée)
- Peu larges
- Clairsemés (x2)



Réseaux de neurones artificiels simples

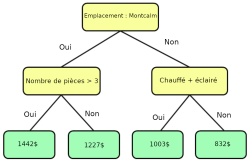
Tâche: prédire le loyer mensuel d'un appartement dans la ville de Québec

Modèle linéaire

$$\hat{y} = 70\$ + 90¢ \cdot \text{nombre de pieds carré} + 58\$ \cdot \text{nombre de pièces}$$

$+$

Arbre de décision



$=$

Réseau à activation binaire

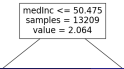
$$\hat{y} = 800 + 200 \cdot \mathbb{1}_{\{\text{nombre de pièces} > 4\}} + 160 \cdot \mathbb{1}_{\{\text{nombre de pieds carré} > 1200\}} + 110 \cdot \mathbb{1}_{\{\text{nombre de pieds carré} > 1400\}}$$

Testons l'*interprétabilité* de notre approche!

La tâche

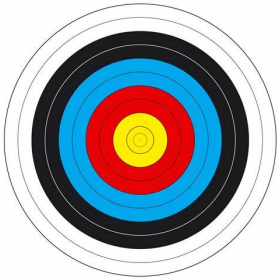
- Prédire la valeur d'une maison (mesuré en 1k USD)
- Caractéristiques retenues (parmi huit):
  - L'âge median des maisons du même quartier (MedAge)
  - Le nombre médian de chambre à coucher des maisons du même quartier (MedBed)
  - Le revenu median des ménages des maisons du même quartier (mesuré en 1k USD) (MedInc)

$$
\begin{aligned}
&B(\text{MedInc, MedAge, MedBed}) = \\
&100 + \\
&101 \cdot \mathbb{1}_{\{0.59 \cdot \text{MedAge} + \text{MedInc} > 63.56\}} + \\
&127 \cdot \mathbb{1}_{\{0.08 \cdot \text{MedAge} + \text{MedInc} > 65.46\}} + \\
&60 \cdot \mathbb{1}_{\{\text{MedInc} > 28.20\}} + \\
&36 \cdot \mathbb{1}_{\{\text{MedBed} > 2.0\}} + \\
&27 \cdot \mathbb{1}_{\{\text{MedAge} > 20.0\}}
\end{aligned}
$$



Améliorations

- ✓ Tâches multivariées
- ✓ Construire des réseaux de neurones profonds
- ✓ Méthode éprouvée sur des données de la vie réelle
- ✓ Monotonie du prédicteur
- ✓ Quantifier la stabilité du prédicteur



Conclusion

Les **réseaux de neurones artificels** peuvent être **interprétables**...
... Lorsque entrainés avec ce but en tête!

Merci de votre attention :)

benjamin.leblanc.2@ulaval.ca

ArXiv : **A Greedy Algorithm for Building Compact Binary Activated Neural Networks**